## AnnotationHub 获取kegg org数据库:除了公开的19个之外,其他的也都可以获取、下载

**笔记本**: R

**创建时间:** 2020/7/14 16:46 **更新时间:** 2020/12/7 11:06

作者: 干冰

**URL:** https://www.bioinfo-scrounger.com/archives/512/

### GO KEGG 富集分析数据库准备

注意: 请使用最新的R下载

### (1) 加载R包、创建链接

```
library(AnnotationHub)
library(AnnotationDbi)
ah <- AnnotationHub()</pre>
```

### (2) 搜索org数据库

```
# 获取所有orgdb
 org <- ah[ah$rdataclass == "OrgDb",]</pre>
 # 搜索 物种
 hm <- query(org, "Homo sapiens") # 人
 hm <- query(org, "mellifera") # 蜜蜂
 hm # 查看搜索结果
 # 结果见下图,得到了很多个,第一个就是目标
 # query的完整写法
 # query(x, pattern , ignore.case=TRUE) pattern 是正则匹配
 # 这里我找一个特殊的物种蜜蜂做示例 https://www.ncbi.nlm.nih.gov/genome/?
 term=txid7460[orgn] Apis mellifera (honey bee)
  hm <- query(org, "mellifera")
AnnotationHub with 4 records
# snapshotDate(): 2018-10-24
# $dataprovider: ftp://ftp.ncbi.nlm.nih.gov/gene/DATA/
# $species: Apis mellifera, Apis mellifera cerana, Apis mellifera dorsata, A.
 $rdataclass: OrgDb
 additional mcols(): taxonomyid, genome, description,
    coordinate_1_based, maintainer, rdatadateadded, preparerclass, tags,
    rdatapath, sourceurl, sourcetype
  retrieve records with, e.g., 'object[["AH67105"]]'
              title
 AH67105 | org.Apis_mellifera.eg.sqlite
  АН6/153 | org.Apis_mellifera_cerana.eg.sqlite
АН67162 | org.Apis_mellifera_florea.eg.sqlite
АН67213 | org.Apis_mellifera_dorsata.eg.sqlite
```

### (3) 下载数据库

org\_db <- ah[["AH67105"]] # 这一步会使用网络下载数据,缓存文件通常保存在个人 ~/.AnnotationHub/id 文件中。见下方截图示例

# (4) 数据库保存、加载 (saveDb不能用了,报错,原因未知,此时请采用4.1备选方案)

```
# 保存到文件,下次直接加载即可
saveDb(org_db, file = "mellifera.orgdb")

# 加载
org_db = loadDb(file = "mellifera.orgdb")
```

### (4.1) 备选数据保存方案

```
cp ~/.AnnotationHub/id abc.orgdb # 直接拷贝数据库缓存文件 org_db = loadDb(file = "abc.orgdb")

文件名建议统一命名为: 物种名称.kegg简称.orgdb escherichia_coli.eco.orgdb 大肠杆菌 honey_bee_apis_mellifera.ame.orgdb 蜜蜂 human.hsa.orgdb 人 mouse.mmu.orgdb 小鼠 rabbit_oryctolagus_cuniculus.ocu.orgdb 兔子 rat.rno.orgdb 大鼠 zea_mays.zma.orgdb 玉米 zebrafish_danio_rerio.dre.orgdb 斑马鱼
```

### 数据库相关操作

columns(org\_db)

O

查看数据库包含哪些信息

```
> columns(org_db)
[1] "ACCNUM" "ALIAS" "CHR" "ENTREZID" "EVIDENCE"
[6] "EVIDENCEALL" "GENENAME" "GID" "GO" "GOALL"
[11] "ONTOLOGY" "ONTOLOGYALL" "PMID" "REFSEQ" "SYMBOL"
[16] "UNIGENE"
```

- head(keys(org\_db, keytype = "SYMBOL"))
  - 获取所有SYMBOL信息

```
> head(keys(org_db, keytype =
[1] "14-3-3zeta" "18-w"
                                   "SYMBOL"), 20)
                                    "18S rRNA"
                                                    "28S rRNA"
                                                                    "5-HT1"
 [6] "5-HT2alpha" "5-HT2beta"
                                    "5-ht7"
                                                    "A4"
                                                                    "ACSF2"
[11] "AChE-2"
                     "AGLU2"
                                    "AQP"
                                                    "ATP5G2"
                                                                    "Abscam"
[16] "Ac3"
                     "Acph-1"
                                    "Ada2b"
                                                    "Adar"
                                                                    "Adk1"
```

# 注意:要完成GO/KEGG分析,org数据库要包含SYMBOL/ENTREZID/GO这三个信息SYMBOL/ENTREZID

- · 这两个信息主要用来把输入基因SYMBOL转化为 ENTREZID (ENTREZID编号唯一, 且 GO/KEGG富集分析用的都是用这个编号,而不 是SYMBOL)
  - 。注意:有的物种不支持ENTREZID转换,下 面做详细说明
- · SYMBOL严格区分大小写,一定要保证与NCBI 一致

### GO:

- · GO富集分析要使用
- · 查看kegg对应物种的ncbi-geneid转换api能否 打开,例如:

http://rest.kegg.jp/conv/hsa/ncbi-geneid

- 。 能打开,一切正常
- 不能打开,则需要换一种映射方式了,请仔细阅读后面的资料

常见的几个数据库

人

```
# retrieve records with, e.g., 'object[["AH66157"]]'

title

AH66157 | org.Mm.eq.db.sqlite

AH66327 | org.Musa_AA_Group.eg.sqlite

AH66328 | org.Musa_acuminata.eg.sqlite

AH66329 | org.Musa_acuminata_AA_Group.eg.sqlite
```

### 大鼠

### 关于KEGG富集分析支持的输入ID说明

kegg支持的物种列表: <a href="https://www.genome.jp/kegg/catalog/org\_list.html">https://www.genome.jp/kegg/catalog/org\_list.html</a>

kegg物种基因id使用: https://www.genome.jp/kegg/genes.html

#### Data Source of KEGG GENES

The following table shows the data source of the KEGG GENES database.

Category	Original DB <sup>1</sup>		Content <sup>2</sup>	Genome identifi	er	Gene identifier	
Eukaryotes	RefSeq		RefSeq release (complete)	T0 numbers		GeneID	
Drokarvotoci	RefSeq		NCBI reference genomes	(three or four le	ŀ	Locus_tag	
	GenBank		Other complete genomes	organism codes		Locus_tag	
Viruses	RefSeq		Refseq release (viral)	T40000 (vg) T4 numbers		GeneID	
Addendum	KEGG		Functionally characterized proteins	T10000 (ag)		ProteinID	

- <sup>1</sup> Original DB name is shown in the definition field of each GENES entry.
- <sup>2</sup> RefSeq bimonthly releases are used to update eukaryotes and viruses. Prokaryoteic genomes are selected from ftp://ftp.ncbi.nlm.nih.gov/genomes/ASSEMBLY\_REPORTS/.
- (1) 通常情况下,富集分析时,我们输入的都是基因symbol
- (2) GO/KEGG 基本不支持symbol的识别,因为symbol存在别名问题
  - 那么就得换一个id作为唯一识别码
- (3) 我们需要org db数据库,把symbol映射为GO/KEGG可识别的标签,通常情况下,就是


### **ENTREZID**

- 查看物种在kegg中使用的基因名称(可以看到,都是一个数字编号,但是也有特殊情况, 例如下面的bmyo)
  - 人 <a href="http://rest.kegg.jp/list/hsa">http://rest.kegg.jp/list/hsa</a>


- 小鼠 http://rest.kegg.jp/list/mmu
- 大鼠 http://rest.kegg.ip/list/rno
- 蕈状芽孢杆菌 <a href="http://rest.kegg.jp/list/bmyo">http://rest.kegg.jp/list/bmyo</a>

```
glutamine amidotransferases class-II family protein
bmyo: BG05_1
bmyo:BG05 2
                aluminum activated malate transporter family protein
bmyo:BG05_3
                ABC transporter family protein
bmyo: BG05_4
               hypothetical protein
bmyo:BG05_5
               ygaB-like family protein
bmyo: BG05 6
               small, acid-soluble spore, gamma-type family protein
bmyo:BG05_7
                putative yfhS
bmyo:BG05_8
                mutY; A/G-specific adenine glycosylase
bmyo: BG05_9
               hypothetical protein
bmyo:BG05_10
                WVELL family protein
bmyo:BG05_11
                sspK; small, acid-soluble spore protein K
bmyo:BG05_12
                ypzG-like family protein
bmyo: BG05_13
                hypothetical protein
bmyo:BG05_14
               recX family protein
bmyo:BG05_15
               NAD dependent epimerase/dehydratase family protein
bmyo: BG05_16
                amidohydrolase family protein
bmyo: BG05_17
                acetyltransferase domain protein
               yfhE-like family protein
bmyo: BG05 18
bmyo:BG05_19
                ugtP; processive diacylglycerol glucosyltransferase
bmyo: BG05_20
               pflA; pyruvate formate-lyase 1-activating enzyme
bmyo:BG05_21
               pflB; formate acetyltransferase
bmyo: BG05_22
               hypothetical protein
                glycosyltransferase like 2 family protein
bmyo:BG05_23
bmyo:BG05_24
                3-beta hydroxysteroid dehydrogenase/isomerase family protein
bmyo:BG05_25
                nucleotide sugar dehydrogenase family protein
bmyo:BG05_26
                glycosyltransferase like 2 family protein
```

通常情况下,KEGG使用的唯一基因标签是ENTREZID,这个ID就是ncbi-geneid,这个ID 是唯一的,不会因为别名改变而改变



o 使用 <a href="http://rest.kegg.jp/conv/hsa/ncbi-geneid">http://rest.kegg.jp/conv/hsa/ncbi-geneid</a> 可以查询物种在kegg中, keggid与ncbi-geneid的映射关系,可以发现,数字编号id是完全一样的,那么, 我们就可以直接使用ENTREZID做富集分了



o 但是,有的物种,在kegg中是不存在ncbi-geneid映射关系的,例如前面说的细 菌 bmyo, http://rest.kegg.ip/conv/bmyo/ncbi-geneid 你会发现无法访问。

- 面对非ncbi-geneid的情况,你就不能用ENTREZID了,需要换一种ID。这就需要你自己找一下org db,哪一个库中是keggid
  - 这里以bmyo为例

1. 查看包含的数据库 columns(org\_db)

```
> columns(org_db)

[1] "ACCNUM" "ALIAS" "ENTREZID" "EVIDENCE" "EVIDENCEALL"

[6] "GENENAME" "GID" "GO" "GOALL" "ONTOLOGY"

[1] "ONTOLOGYALL" "PMID" "REFSEQ" "SYMBOL"
```

- 2. 查看数据库的中内容 head(keys(org db, keytype = "ALIAS"))
  > head(keys(org\_db, keytype = "ALIAS"))
  [1] "BG05\_10" "BG05\_100" "BG05\_1000" "BG05\_1001" "BG05\_1002" "BG05\_1003"
- 3. 发现,上面的ALIAS就是KEGGID,那么,富集分析时,上面的id就是 转换目标

### KEGG目前的总结:

- 1. 查看物种在kegg里的kegg id <u>http://rest.kegg.jp/list/hsa</u>
- 2 查看物种在kegg中是否存在ncbi-geneid 映射关系 <a href="http://rest.kegg.jp/conv/hsa/ncbi-geneid">http://rest.kegg.jp/conv/hsa/ncbi-geneid</a>
  - 1.如果有,那么基本上id映射方式就是 ENTREZID
  - 2 如果没有,那么,就需要打开org\_db, 查一下哪个数据库能与 list/物种 列表里的keggid 对应上
    - 1.目前来看,通常是ALIAS数据库对应kegg 编号
- 注意:并不是所有kegg列出来的物种,都有org数据库,只是某一个菌群存在数据库,例如Rahnella只有 raa有orgdb

Chania	sfo	Chania multitudinisentens	2014	GenBank
	rah	Rahnella sp. Y9602	2011	GenBank
Rahnella	raq	Rahnella aquatilis CIP 78.65 = ATCC 33071	2012	GenBank
Kalillella	raa	Rahnella aquatilis HX2	2012	GenBank
_	rox	Rahnella sp. ERMR1:05	2018	GenBank
	-		1	

1.所以,在创建物种数据库前,先看一下kegg 支持哪一个菌群

